

Прогноз выгодности перевода в любой момент

Подробное описание итогового подхода

Задача состоит из двух разных продуктов. Первый выбирает редкие моменты для push: примерно один-два сигнала на валютный коридор в неделю. Второй отвечает пользователю, который открыл приложение в произвольный момент: показывает «температуру» от 0 до 100, ожидаемую выгоду и свежесть данных.

Что готово	Значение
Валюты	AMD, KGS, KZT, TJS и UZS
Горизонты	1, 3, 5, 10 и 20 следующих публикаций ЦБ
Сильный sparse push	AP37, adjusted lift h5 = 2,509, частота 1,038 в неделю
Непрерывный ответ	T17/T18-router: утро, рынок, receipt ЦБ, вечер, ночь, выходные
Единый T19-аудит	193 400 запросов на 967 днях и 20 моментах суток
Защита от будущего	walk-forward, mature labels, embargo, completed candles, verified receipt

Самое важное ограничение: курс ЦБ служит открытым проху, а не ценой исполнения в приложении. Поэтому lift и базисные пункты доказывают качество сигнала на публичном ряду. Реальную экономию, выручку и инкрементальный объем сможет доказать только банковский пилот с фактическими quote, комиссиями и holdout.

1. Что именно просит кейс

Главная задача и задача со звёздочкой

Основная задача кейса: по открытым курсам построить сигнальный слой, который отвечает, появился ли повод написать клиенту о переводе в конкретную страну. Сигнал должен оказаться информативнее случайного дня, быть объяснимым и не сжигать ограниченный коммуникационный ресурс.

Задача со звёздочкой: что показать человеку, если он открыл уведомление позже, а ситуация уже изменилась. Наша «температура» закрывает именно этот разрыв: при каждом входе приложение запрашивает свежий допустимый snapshot, а не повторяет число из старого push.

Требование ТЗ	Как закрываем
Пять коридоров	считаем все AMD/KGS/KZT/TJS/UZS
Классический ML	логистическая модель, Ridge, boosting, правила и роутеры
Два типа сигнала	«сейчас выгодно» и «окно закрывается»
Пять горизонтов	$h = 1/3/5/10/20$ публикаций ЦБ
Частота	сар не более двух сигналов в ISO-неделю
Произвольный срез T	<code>`signals_as_of(T)`</code> и <code>`case_output_runtime_as_of(T)`</code>

Приоритет остаётся у sparse-сигнала. Красивый экран не компенсирует слабую модель. Поэтому в отчёте сначала доказан AP37, а затем описан интерфейсный контур температуры.

2. Какие данные мы используем

Дневной ряд ЦБ и внутридневной рынок

Базовый ряд содержит официальный курс ЦБ в рублях за указанный номинал валюты. Номинал нормируется построчно: 100 сумов и 1 сум нельзя сравнивать как одинаковые единицы. Горизонт измеряется следующими публикациями ЦБ, а не календарными сутками, поэтому выходные не создают искусственные «нулевые» дни.

Внутри дня добавляются открытые воспроизводимые данные MOEX. Основной общий индикатор рынка даёт CNYRUB: движение юаня к рублю хорошо отражает общую силу рубля. В вечерних моделях также используется USDRUB. Прямая биржевая пара для каждой целевой валюты либо отсутствует, либо недостаточно ликвидна, поэтому модель сочетает общий рыночный фактор с собственным дневным рядом коридора.

Источник	Что даёт	Когда доступен
ЦБ	level, momentum, режим, календарь	после фактической публикации записи
CNYRUB spot	общий intraday move рубля	только после закрытия свечи
CNYRUBF perpetual	ранний и поздний market-prefix	только завершённые часы
USDRUBF perpetual	второй глобальный фактор	завершённые вечерние часы

Если свечи нет, система не рисует её из соседнего дня. T17 удалил 6 800 таких фиктивных snapshot. Если новый курс ЦБ не получен, T18 не включает after-publication модель только потому, что на часах уже 18:30.

3. Что такое один объект и один таргет

Мы предсказываем качество момента, а не точное число курса

Для валюты `с`, даты `t` и горизонта `h` берём курс, действующий сейчас, `R(c,t)`. Затем смотрим только при расчёте метрики на следующие `h` публикаций. Основная бинарная цель равна единице, если сегодняшний курс не хуже всех этих будущих значений. Простыми словами: после нашего «переводить сейчас» клиент не увидел бы более дешёвую официальную цену в заданном горизонте.

Вторая цель «окно закрывается» проверяет, что после сигнала курс действительно вырос. Это отдельная задача с другой базовой частотой. ТЗ требует считать обе, поэтому нельзя выдать хороший результат одной цели за закрытие всей задачи.

Горизонт	Интуитивный смысл
h1	следующая публикация ЦБ
h3	примерно ближайшие несколько рабочих дней
h5	около рабочей недели публикаций
h10	около двух рабочих недель
h20	длинный горизонт около месяца публикаций

После получения курса на завтра `h1` частично превращается из прогноза в проверку уже известного значения. Мы сохраняем строку h1, потому что она обязательна по ТЗ, но не рекламируем вечерний h1 как достижение forecasting.

4. Две выгоды, которые нельзя смешивать

Официальная $\pm h$ и достижимая future-only

ТЗ задаёт «выгоду момента» как разницу между курсом дня и средним в симметричном окне $\pm h$. В левой половине окна лежит прошлое. Модель могла получить высокий балл просто после уже случившегося падения, хотя клиент не может вернуться назад и перевести вчера.

Поэтому мы всегда показываем две величины:

Метрика	Вопрос
Симметричная выгода $\pm h$	выполняется ли формальная метрика кейса
Future-only выгода	сколько преимущества относительно только будущих публикаций

Future-only не заменяет официальную метрику. Она добавлена как продуктовая диагностика: описывает часть окна, которой клиент ещё может воспользоваться. Обе величины считаются в базисных пунктах официального курса. 100 б.п. равны примерно 1% относительного изменения.

Даже future-only б.п. нельзя автоматически переводить в рубли. Курс банка содержит спред, может отличаться по направлению и сумме, иметь срок действия, комиссию и лимиты. До подключения этих полей корректная подпись звучит как «ожидаемое преимущество по публичному ряду ЦБ», а не «вы сэкономите X рублей».

5. Как устроена честная проверка

Каждая дата симулирует реальное прошлое

Для тестовой даты `t` модель видит только информацию, реально доступную к `as\_of`. Метка для горизонта h попадает в обучение лишь после того, как прошли все h будущих публикаций. Дополнительно используется двухдневный embargo между последней созревшей меткой и тестовым решением.

1. Даты идут по порядку, случайного перемешивания нет.
2. Fit выполняется на созревших прошлых метках.
3. Признаки рынка берутся только из полностью закрытых свечей.
4. Калибратор вероятности обучается на прошлом, а не на тестовом году.
5. Corruption-тест подменяет будущие данные и требует неизменности прошлого ответа.

Главный baseline тоже честный: среднее по уникальным прошлым событиям, метки которых созрели до `query\_day - 2 дня`. Одна дневная метка не размножается двадцать раз из-за двадцати моментов внутридневной сетки.

Открытый период 2024-2026 уже много раз использовался для диагностики. Его результаты сильны как воспроизводимая ретроспектива, но больше не являются fresh holdout. Следующая независимая проверка возможна только после заморозки модели на prospective shadow.

6. Самый сильный sparse-подход AP37

Почему это не «просто бустинг»

AP37 представляет собой управляемую политику поверх нескольких причинных моделей. Базовый expert оценивает вероятность хорошего момента по истории ЦБ, рыночным признакам, валюте и режиму. Затем router выбирает только состояния с достаточной mature precision. Cooldown и недельный cap превращают плотный ряд оценок в редкие сообщения.

Упрощённая логика:

1. Собрать доступные признаки на текущий момент.
2. Получить probability и expected future benefit.
3. Сравнить confidence с порогом конкретной валюты и режима.
4. Разрешить сигнал только при положительной ожидаемой выгоде.
5. Не отправлять повтор сразу после недавнего сигнала.
6. Не превышать два сигнала на валюту в ISO-неделю.

В AP37 core берётся из AP26, fallback из AP23. Mature-precision gate не верит модели только потому, что она уверенно звучит: он проверяет её прошлую точность в сопоставимом режиме. Благодаря этому итоговый поток одновременно имеет высокий lift и нужную частоту, чего простые индикаторы по отдельности не дают.

7. Метрики AP37 по горизонту

«Сейчас выгодно», общий открытый период 2024-2026

h	Adjusted lift	Симм. `±h`, б.п.	Future-only, б.п.
1	1,944	+30,89	+92,69
3	2,429	+61,97	+124,19
5	2,509	+74,55	+133,73
10	2,479	+79,47	+133,10
20	2,525	+88,55	+130,23

На h5 имеется 3 260 доступных OOS-событий и 695 сигналов. Hit rate сигнала 73,38%, а базовая частота случайного дня 29,45%. Их отношение с принятой коррекцией даёт adjusted lift 2,509. Средняя частота составляет 1,038 сигнала на валюту в неделю.

Что значит lift 2,509: выбранные моделью дни подтверждают утверждение примерно в 2,5 раза чаще, чем случайный день того же коридора и периода. Это не означает рост курса в 2,5 раза и не означает прибыль 150%.

Point-результат заметно выше порога 1,3. Но поздний период открыт, поэтому корректная формулировка: «сильный ретроспективный кандидат, готовый к заморозке и shadow», а не «гарантированная production-модель».

8. Устойчивость AP37 по валютам

h5: худший коридор тоже выше порога

Показатель	Диапазон по пяти валютам
Hit rate	68,1-76,6%
Lift	2,334-2,603
Частота	1,023-1,061 сигнала в неделю
Симметричная выгода	минимум +71,29 б.п.
Future-only выгода	минимум +127,44 б.п.

Пять строк валют нельзя считать пятью полностью независимыми экспериментами: общий фактор рубля делает коридоры коррелированными. Однако разрез полезен как проверка переносимости. Результат не держится только на одной удобной валюте.

Для второй цели «окно закрывается» h5 lift по валютам находится в диапазоне 1,514-1,582. На самом сложном h20 он снижается до 1,308-1,365. Формально порог 1,3 пройден везде, но запас h20 минимален, поэтому именно этот участок требует prospective подтверждения.

Частота считается по коридору, как требует scorecard кейса. Реальный банк должен добавить общий сар по клиенту и всем кампаниям: человек может получать другие коммуникации, а модель этого не видит.

9. Почему простые индикаторы не стали финалом

Они нужны для объяснения, но недостаточны по отдельности

Индикатор, h5	Lift min-max	Частота min-max
Падение 3 публикации	0,712-1,038	0,620-0,807
Нижний дециль	0,745-0,951	0,784-1,233
Разворот вверх	0,460-1,034	0,381-0,463
Сезонность/праздники	0,756-1,021	0,351-0,949
Верх диапазона	1,228-1,698	0,418-0,702
AP37	2,334-2,603	1,023-1,061

Momentum легко срабатывает после падения. Симметричное окно награждает его за прошедшее движение, но future-only часть часто оказывается слабой. Level без контекста режима путает настоящий минимум с продолжающимся трендом. Сезонность хрупка из-за короткой истории и смены валютного режима после 2022 года.

Финальный ансамбль не выбрасывает эти признаки. Он использует их как понятные части общего состояния вместе с волатильностью, рыночным движением, валютой, режимом и качеством источника. В клиентский текст выводится наблюдаемый факт, например положение в прошлом диапазоне, а не скрытое обещание будущего.

10. Почему 2022 год важен, но не является магической кнопкой

Режим рынка изменился

После 2022 года изменились волатильность, структура валютного рынка и доступ к международным расчётам. В старой презентации видно, что 2022 год занимает лишь 13,1% наблюдений, но объясняет 57,6% дисперсии доходностей. Один глобальный порог, одинаковый для спокойных и шоковых лет, плохо калибруется.

Мы учитываем режим тремя безопасными способами:

- causal rolling volatility и другие признаки только по прошлому;
- большой training weight более свежих наблюдений;
- валютные и режимные взаимодействия с shrinkage к общей модели.

Нельзя посмотреть весь 2024-2026 тест, выбрать «разрез после СВО» и объявить это честным улучшением. Любая граница, вес или router должны быть заданы на раннем периоде либо зарегистрированы до открытия результата. Поэтому T19 лишь обнаруживает локальный drift и формулирует следующий эксперимент, но не перенастраивает модель постфактум.

Бизнес-смысл режима прост: одинаковая температура должна означать близкую вероятность и в спокойный, и в стрессовый год. Сейчас pooled calibration выглядит хорошо, а узкие валютно-годовые срезы ещё плавают.

11. Температура 0-100

Что означает число на экране

Температура равна калиброванной вероятности, умноженной на 100. Например, температура 73 на h5 означает: среди исторически похожих причинно доступных состояний примерно 73% подтверждали условие «действующий курс не хуже следующих пяти публикаций».

Она не означает:

- 73% прибыли;
- гарантию, что завтра курс вырастет;
- вероятность исполнить перевод по официальному курсу ЦБ;
- автоматическое разрешение отправить push.

Рядом живёт `expected_future_cbr_bps_h`. Это отдельная модель размера эффекта. Вероятность может быть высокой при маленьком ожидаемом преимуществе, либо наоборот. Поэтому *probability* оценивается Brier/AUC/ECE, *magnitude* оценивается MAE и rank correlation, а *push* оценивается lift/cadence.

На слабых состояниях API обязан вернуть `limited confidence`. Число можно показать для непрерывности интерфейса, но подпись должна честно сказать, что исторические данные не дают выраженного сигнала.

12. Один день модели, как для школьника

Кто отвечает в каждый момент

Время Москвы	Что уже известно	Что делает система
Ночь и раннее утро	история ЦБ	history-only fallback
09:00-10:30	первые completed market часы	ранний h1/h3 expert, остальное fallback
10:30-15:30	растущий market-prefix	обновляет probability и benefit
15:30-receipt	новые свечи, но нет нового ЦБ	bridge без знания завтрашнего курса
После receipt	курс на завтра действительно получен	after-publication anchor
19:00-23:00	новые spot/perpetual свечи	уточняет только доказанные головы
Выходной	новых данных нет	держит snapshot и увеличивает age

В 11:45 модель не может использовать свечу 15:30: это будущее. В 17:45 она может использовать завершённую свечу 16:30. В 18:45 она не имеет права знать новый курс ЦБ, если ingestion не зафиксировал `verified\_receipt\_at`.

Probability и benefit могут иметь разные часы источника. Например, в 21:15 вероятность остаётся от spot-снимка 20:00, а expected h5 benefit уже использует perpetual-prefix 20:59:59. Интерфейс показывает оба timestamp.

13. Почему важна граница 15:30

Это информационная фаза, а не мистическое лучшее время

15:30 возникло как один из исследуемых market cutoffs, близкий к концу основной части дня, когда уже накоплен богатый prefix. Модельное семейство одно, но в 11:00 оно работает на коротком prefix, а в 15:30 на более длинном. Нельзя буквально подставить в 11:00 признаки будущих свечей до 15:30.

На 2024 screen разные допустимые cutoffs давали minimum official lift примерно 1,50-1,58. 15:20 был выбран как сильный screen-вариант. На открытом 2025-2026 15:20 и 15:30 близки. Поэтому правильный вывод: качество нарастает по мере накопления completed candles, а не «ровно в 15:30 рынок сообщает истину».

После 15:30 удерживать последнее число причинно допустимо, но оно стареет. Bridge-модели T3/T12 используют новые закрытые свечи 16:30/17:30 для будущих шагов. Они не утверждают, что меняют уже рассчитанный будущий фиксинг ЦБ; они обновляют привлекательность текущего перевода на горизонте нескольких следующих публикаций.

14. Что происходит после нового курса ЦБ

Знание курса на завтра можно использовать после фактического receipt

T3 прямо говорит: курс на завтра публикуется сегодня, поэтому сигнал опирается на последний опубликованный курс. Это разрешает использовать новое значение как вход после его доступности. Одновременно действует запрет на заглядывание: до receipt этот курс использовать нельзя.

Текущий target стартует от курса ЦБ, действующего сегодня. Новый объявленный курс становится сильным признаком будущего пути. Для h1 он уже раскрывает следующий шаг, а для h3/h5/h10/h20 остаются неизвестные публикации.

Исторические точные timestamp публикации отсутствуют. Поэтому есть два явно разделённых режима:

Режим	Смысл
`calendar_assumed_replay`	research-only предположение receipt в 18:30
`no_same_day_receipt`	production-safe удержание pre-receipt состояния

T18 требует реальный `verified\_receipt\_at`. Поздний receipt сдвигает `valid\_from` всех зависимых snapshot. Обычный CLI не активирует новый expert по настенным часам. Это важнее небольшого прироста метрики: без этой защиты вечерний результат мог бы оказаться утечкой доступности.

15. T19: единый аудит произвольного времени

Проверено 193 400 запросов

T19 берёт 967 календарных дней 2024-2026, 20 моментов внутри суток, пять валют и два receipt-сценария. В каждом запросе считаются все пять горизонтов.

Проверка	Результат
Запросов на сценарий	96 700
Всего запросов	193 400
Receipt-сценариев	2
Состояний `scenario × clock × h`	200
Probability PASS	111 / 200
Expected benefit PASS	119 / 200

PASS требует, чтобы верхние границы paired moving-block bootstrap и для блока 20 дат, и для блока 50 дат были ниже нуля. Для probability сравнивается Brier, для benefit сравнивается MAE. Это существенно строже, чем просто увидеть красивое среднее улучшение.

Аудит также подтверждает `source\_at <= query\_at`, наличие snapshot на каждом запросе, правильное совпадение effective index и отсутствие same-day receipt в безопасном сценарии.

16. Как h5 улучшается в течение дня

Открытая диагностика 2024-2026

Время	Brier	AUC	MAE future bps	PASS prob/benefit
00:15-09:15	0,2126	0,527	110,15	нет / нет
10:15	0,1978	0,649	110,15	нет / нет
10:45	0,1940	0,669	106,70	нет* / да
11:45	0,1921	0,679	106,08	да / да
15:45	0,1875	0,697	104,50	да / да
16:45	0,1862	0,705	102,96	да / да
17:45	0,1868	0,701	103,41	да / да
18:45 после assumed receipt	0,1801	0,719	91,70	да / да
19:15	0,1784	0,724	91,07	да / да
21:15	0,1788	0,719	90,25	да / да

^^ В 10:45 point Brier лучше, но 50-day верхняя граница равна +0,00021. Поэтому строгий probability gate включается только позднее.

Без подтверждённого receipt вечер честно держит 17:45: Brier 0,1868, AUC 0,701 и MAE 103,41. После реального receipt сильный скачок допустим, потому что появился новый открытый факт, а не потому, что мы сгладили линию руками.

17. Где температура пока слаба

Не все горизонты заслуживают одинаковой уверенности

Горизонт	Probability PASS, replay	Benefit PASS, replay
h1	18 / 20	16 / 20
h3	18 / 20	16 / 20
h5	15 / 20	16 / 20
h10	0 / 20	12 / 20
h20	0 / 20	0 / 20

До рынка history-only h5/h10/h20 хуже прошлого constant baseline. Для h20 ранний AUC около 0,458, а Spearman expected-bps около -0,254. Это fallback с `limited confidence`, а не сильный forecast.

На всей сетке pooled ECE не превышает примерно 0,050. Однако в 1 629 из 3 000 узких срезов `валюта × год × время × h` ECE выше 0,08. Например, ранний UZS h5 в 2024 имеет ECE около 0,123. Общая аккуратная линия скрывает локальный drift.

Эта таблица описывает исходный T19, а не финал исследования. T20-T36 затем разобрали проблему на rank, probability level и information-state routing. T37 впервые закрыл именно h20-gap на той же открытой ретроспективе: 40/40 объединённых `scenario × clock` gates, pooled Brier/AUC bootstrap и улучшение pooled ECE. T38 уточнил локальную картину: все годовые срезы устойчивы, но валютная ECE и интервалы малых `currency × year` групп проходят не везде. Поэтому T37 остаётся prospective shadow, а таблицу T19 нельзя задним числом переписать как независимый тест.

18. Как измеряются probability и magnitude

Три вопроса требуют разных метрик

Выход	Основные метрики	Хорошее направление
Вероятность	Brier, log-loss, ECE, AUC	Brier/ECE вниз, AUC вверх
Ожидаемые б.п.	MAE, Spearman, calibration bins	MAE вниз, rank вверх
Sparse push	hit rate, lift, benefit, cadence	lift/benefit вверх, частота в полосе

Brier наказывает и за ошибку, и за самоуверенность. AUC проверяет ранжирование: ставит ли модель хорошие дни выше плохих. ECE проверяет смысл числа: если модель часто показывает 70, происходит ли событие примерно в 70% случаев.

MAE отвечает, насколько модель ошибается в размере будущего преимущества. Даже идеально откалиброванная вероятность может плохо оценивать количество базисных пунктов, поэтому magnitude обучается и маршрутизируется отдельно.

Lift не подходит для непрерывного виджета. Он оценивает только отобранные события и зависит от порога. Поэтому высокий lift sparse push не доказывает, что каждое число 0-100 на экране правильно откалибровано.

19. Вечерняя модель размера эффекта

T15/T16 используют новые CNYRUBF и USDRUBF свечи

После reseipt базовый прогноз уже знает опубликованный курс. Вечером рынок продолжает двигаться, и это помогает оценить не только вероятность события, но и размер преимущества на h3/h5. T15 обучает global Ridge на остатке базового after-publication прогноза.

Время	Принятые h	MAE T15	MAE контроля	Улучшение
20:00	h3	53,98	58,08	-4,10
21:00	h3 / h5	53,72 / 83,00	58,08 / 87,88	-4,36 / -4,87
22:00	h3 / h5	53,95 / 82,09	58,08 / 87,88	-4,13 / -5,79
23:00	h3 / h5	53,14 / 80,85	58,08 / 87,88	-4,93 / -7,03

Новая голова принимается только когда обе bootstrap-границы screen-2024 ниже нуля. Вечерние probability-кандидаты такого доказательства не дали, поэтому T16 обновляет magnitude, но не «освежает» вероятность ради красивого UI.

На открытом 2025-2026 эффект меньше, но обычно того же знака. Это screen-кандидат, а не новый независимый победитель.

20. Что происходит в выходной и при пропуске данных

Непрерывность не означает выдуманное обновление

ЦБ в выходной может не публиковать новое значение, а биржа может быть закрыта. Система выбирает последний snapshot, который действительно был доступен, и увеличивает его ``age_minutes``. После порога состояние становится ``aging``, затем ``stale``.

Если новый источник отсутствует:

- температура не двигается искусственно;
- timestamp остаётся старым;
- интерфейс показывает ограниченную свежесть;
- тексты про «новое движение рынка» запрещаются;
- sparse push может быть подавлен политикой freshness.

Метка горизонта строится по публикациям ЦБ. Выходной без новой публикации не считается отдельным нулевым изменением. Это защищает momentum, rolling windows и базовую частоту от календарного артефакта.

Для production необходим мониторинг ingestion: отсутствие события может означать нормальный выходной или поломку канала. Модельный payload уже несёт ``source_kind``, ``last_source_at``, ``availability_evidence`` и ``freshness``, чтобы инфраструктура могла различить эти случаи.

21. Как выглядит ответ API

Минимальный контракт с интерфейсом

Группа	Поля
Идентификатор	`currency`, `horizon_publications`, `score_as_of`
Основной ответ	`temperature_0_100`, `label`, `confidence`
Размер	`expected_future_cbr_bps_h`
Probability provenance	`last_source_at`, `age_minutes`, `freshness`, `source_kind`
Benefit provenance	`benefit_last_source_at`, `benefit_age_minutes`, `benefit_source_kind`
Роутинг	`phase`, `availability_evidence`
Коммуникация	`push_now`, reason code, cooldown state
Receipt	`receipt_verified`, `receipt_at`

Обязательный case output дополнительно содержит `date`, `corridor`, `indicator`, `direction`, `strength`, `indicator\_speed`, `recommended\_scenario`.

Если пользователь открывает старый push, приложение передаёт текущее время в `score\_as\_of`. Экран показывает новый допустимый snapshot и может сравнить его со snapshot отправки. Старый push остаётся в decision log, но не управляет текущей температурой.

22. Как оптимизировать бизнес-метрику

Офлайн качество сигнала и ценность банка не одно и то же

Кейс объясняет бизнес-потенциал как долю клиентов, чей перевод реально сдвигается коммуникацией, умноженную на средний чек и маржу. Клиентских данных на хакатоне нет, поэтому это нельзя честно восстановить из курса ЦБ.

Слой	Офлайн	В пилоте
Sparse push	lift, hit rate, benefit, cadence	incremental conversion и net volume
Виджет	Brier, ECE, AUC, MAE, freshness	transfer completion после просмотра
Доставка	staleness, latency, cooldown	unsubscribe, complaints, fatigue

Северная звезда пилота: инкрементальный чистый объём переводов на eligible пользователя относительно user-level holdout. Если доступна корректная маржа, следующий уровень: incremental contribution margin после комиссий и стоимости коммуникации.

CTR push остаётся диагностикой. Он может вырасти из-за эмоционального текста, не создав ни одного дополнительного перевода. Аналогично, рост числа переводов без 7/30-дневной проверки может быть простой каннибализацией: клиент перевёл раньше, но суммарный объём не изменился.

Для защиты Q&A рекомендует не каталог метрик, а 2-3 числа, по которым принято решение. Для основной задачи это worst-corridor lift, официальная $\pm h$ -выгода и cadence. Brier/AUC/ECE T37 показываются отдельно только для задачи со звёздочкой; T38 рядом показывает её локальную устойчивость. Ими нельзя заменить обязательный lift sparse-сигнала.

23. Дизайн пилота и guardrails

Как доказать реальный бизнес-эффект

1. До старта заморозить AP37, T37 shadow, T38 evidence packet, пороги и тексты.
2. Рандомизировать на уровне пользователя, а не отдельного push.
3. Treatment получает виджет и/или push, control видит обычный путь.
4. Логировать решения даже когда push не отправлен.
5. Хранить фактические quote, fee, amount, source timestamps и freshness.
6. Заранее задать окно конверсии и мощность теста.
7. Проверять переносимость по всем пяти коридорам.

Guardrails: отписки и mute, жалобы, общий коммуникационный cap, задержка доставки, stale open, расхождение ЦБ-проху и bank quote, снижение суммы, каннибализация будущих переводов, концентрация эффекта на одном режиме.

Две продуктовые ветки лучше тестировать факторно, если хватает выборки: виджет без push показывает ценность контекста при естественном входе, sparse push проверяет способность сдвинуть момент перевода. Их объединённая группа показывает полный путь. Если выборки мало, приоритет остаётся у основной задачи кейса: доказать сигнал и push-политику.

24. T20: простая иерархическая калибровка не помогла

Frozen probability оказалась устойчивее

T20 заранее зафиксировал fit на созревших данных 2024 года и один раз применил его к открытому 2025-2026. Primary-модель корректировала probability общей Beta-картой, валютой и информационным режимом. Она не меняла AP37, benefit или availability router.

h	Δ Brier	Δ log-loss	Δ ECE	Строгий PASS
5	+0,00591	+0,01484	+0,01944	0 / 40
10	+0,00394	+0,01150	+0,01850	0 / 40
20	-0,00030	+0,00060	+0,01102	0 / 40

Ноль из 120 state gates прошли. Число узких строк с ECE > 0,08 выросло с 789 до 816. Причина: один 2024 год недостаточен для стабильных режимных поправок, а слабый h20 требует улучшения discrimination, которое калибратор создать не может.

Production сохраняет frozen probability. Следующий шаг должен быть новой long-horizon моделью либо заранее фиксированным prospective online update, а не перебором коэффициентов на уже открытом периоде.

25. T21: h20 лучше ранжируется, но это ещё не температура

Cross-horizon признаки содержат сигнал

T21 заранее зафиксировал новую h20-голову. Она видит только доступные к запросу probability и expected-bps для h1/h3/h5/h10/h20, форму этой кривой, валюту, относительное положение среди пяти коридоров, возраст и режим источника. Base заканчивается до 01.09.2024, calibration - до 2025; обе части используют только созревшие h20-метки с embargo.

Модель	AUC	Brier	ECE	Статус
Frozen h20	0,576	0,118	0,035	текущий fallback
Curve logistic	0,682	0,443	0,460	rank-only diagnostic
HGB + Platt, primary	0,586	0,181	0,239	0/40 gates, отклонён
ExtraTrees + Platt	0,649	0,175	0,236	control, отклонён

Logistic rank улучшает AUC во всех 40/40 состояниях. Но pre-2025 mapping сильно завышает уровень вероятности на 2025-2026, где доля положительного target около 13,7%. Пользователю нельзя показывать «68» только потому, что rank стал лучше: температура обязана сохранять вероятностный смысл.

116 400 evaluation-строк прошли независимый audit source time, maturity, embargo, bounded probability и подмену test target. AP37 и production router не изменены. T22 ниже проверяет заранее фиксированную малую rank-поправку.

26. T22: h20-поправка полезна после receipt

Граница проходит по информации, а не по часам

T22 сохранил frozen probability anchor и добавлял к его logit малую cross-horizon rank-поправку. Вес выбирался только на disjoint конце 2024 под ограничениями Brier, log-loss и ECE; открытый 2025-2026 вес не менял.

Срез	AUC frozen → T22	Brier frozen → T22	PASS
Весь день, 40 states	0,576 → 0,569	0,11828 → 0,11897	6 / 40
После assumed receipt, 6 states	0,534 → 0,671	0,12058 → 0,11379	6 / 6
No same-day receipt	Δ -0,0387	Δ +0,00242	0 / 20

Прошли ровно шесть состояний 18:45-23:15, где доступен новый announced CBR. Их средний log-loss снизился с 0,40723 до 0,38313, ECE не ухудшился. Во всех сценариях без receipt поправка вредна. Следовательно, полезно само событие получения записи, а не наступление фиксированных 18:00 или 18:30.

116 400 строк прошли независимый audit maturity, source time, alpha selection и target corruption. Из-за открытого evaluation и условных исторических receipt-времен T22 остаётся frozen shadow-challenger. Production может включать его только после фактического `verified\_receipt\_at`; до события сохраняется frozen h20 с limited confidence.

27. T23: частая delayed-калибровка добавляет шум

Созревшие метки ещё не гарантируют устойчивый выбор

T23 обновлял mapping раз в месяц. Каждый fit видел только h20-исходы, которые полностью созрели до monthly origin минус embargo. Последние 200 полных дат делились 75/25: ранняя часть обучала anchor/joint logit, trailing screen выбирал между ними и frozen identity. Текущий месяц был полностью скрыт.

Модель	AUC	Brier	Log-loss	ECE
Frozen h20	0,576	0,11828	0,39694	0,03482
Delayed selected	0,554	0,12020	0,40635	0,04175
Всегда anchor-logit	0,417	0,13459	0,46324	0,09239
Всегда joint-logit	0,536	0,13795	0,44875	0,09014

Из 800 месячных состояний identity выбран 619 раз, joint 156, anchor 25. Эти 181 переключение оказалось достаточно, чтобы итог прошёл 0/40 gates. На after-receipt states point AUC/Brier улучшаются, но block-bootstrap пересекает ноль; frozen T22 остаётся сильнее с 6/6 passes.

Практический вывод: не обновлять mapping чаще и не ослаблять gate. После verified receipt замораживаем T22 как shadow; до receipt ищем новые признаки, а не маскируем слабую discrimination перекалибровкой.

28. T24: history-only h20 rank стал СИЛЬНЫМ

Новый сигнал найден, но probability gate его остановил

T24 использует 41 объяснимый признак из завершённой истории: положение курса в диапазонах 30/90/180, returns до 250 публикаций, volatility, moving averages, USD/CNY/peer context, cyclical calendar и currency one-hot. Выходной удерживает score последней публикации и не добавляет фиктивные нулевые изменения.

Период	AUC frozen	AUC compact	Brier frozen → compact
Selection-2024	ниже 0,742	0,742	0,20538 → 0,21555
Open 2025-2026	0,374	0,702	0,12429 → 0,11744

Rank переносится: compact AUC равен 0,662-0,743 по пяти валютам и 0,616/0,699 по 2025/2026. Но selection-period Platt mapping сильно недооценил base rate и ухудшил ECE до 0,141. Зарегистрированный selector поэтому оставил identity, а красивый открытый результат не использован для post-hoc promotion.

Это первый сильный premarket h20 rank после T19. В shadow можно сохранять его рядом с текущей температурой; в UI он попадёт только после заранее заданного anchor-preserving mapping и независимой проверки. T22 остаётся отдельным after-receipt shadow.

29. T25: anchor сохранили, но неопределённость осталась

Rank улучшает температуру, однако promotion преждевременен

T25 заранее зафиксировал шесть residual-весов и три способа переноса rank. Compact-модель обучена до 2024; 2024-H1 определяет карту, 2024-H2 выбирает кандидата, 2025-2026 только измеряет результат. Выбран `residual\_a040`:

``new_logit = frozen_logit + 0,40 × standardized_extra_rank`.`

Open 2025-2026	Frozen h20	T25
AUC	0,374	0,563
Average precision	0,102	0,209
Brier	0,12429	0,11825
Log-loss	0,42016	0,40454
ECE	0,03608	0,03326

AUC-delta имеет положительные 20/50-date 95% CI: [+0,078; +0,284] и [+0,070; +0,301]. Но верхние границы Brier-delta равны +0,00088 и +0,00244 - ноль не исключён. Поэтому заранее заданный joint gate возвращает `false`.

Режимный разрез объясняет осторожность: в 2025 Brier улучшается на 0,01120, а в 2026 ухудшается на 0,00263, потому что score недооценивает выросший base rate. Полный copula переносит AUC 0,702, но ECE становится 0,122; это rank, а не честная вероятность. T25 остаётся premarket shadow. Следующий кандидат может адаптировать только intercept по уже созревшим прошлым исходам; ручной switch по 2022/2026 запрещён.

30. T26: delayed calibration пока не повышена

Честный selector важнее красивого открытого результата

T26 меняет только общий intercept T25. На дату запроса разрешены исключительно уникальные CBR-события, чей полный h20-outcome созрел до даты минус двухдневный embargo. Выходные и удерживаемые значения не создают новые feedback-строки.

Selection 2024-H2	T25	w30
AUC	0,716	0,767
Brier	0,17693	0,17479
Log-loss	0,53047	0,51972
ECE	0,07575	0,08633

w30 превысил разрешённое ухудшение ECE: +0,01058 вместо максимум +0,005. Окна 60/125/250/expanding и hierarchical control также не прошли совместный gate. Поэтому formal selector оставил T25 побитово без изменений.

На открытом 2025-2026 w250 диагностически даёт AUC 0,638, Brier 0,11326 и log-loss 0,38634 против 0,563/0,11825/0,40454 у T25. Но до 2025 доступной истории было меньше 250 дат: w250 почти совпадал с expanding, а его преимущество стало видно только после открытия evaluation. Это полезная post-hoc гипотеза, не новый winner. Следующий честный шаг - построить rolling-origin историю до 2025 либо ждать prospective outcomes.

31. T27: ранняя OOS-история отвергла w250

Красивый поздний эффект не перенёлся назад

T27 добавил 247 уникальных publication dates 2023. Anchor взят из квартальных OOS-вероятностей T4; compact rank получен четырьмя отдельными quarterly fits, видевшими только прежние mature h20-labels с embargo. Теперь длинные окна можно различить до 2025.

Selection 2024-H2	AUC	Brier	ECE
T25 base	0,716	0,17693	0,07575
w30	0,767	0,17479	0,08633
w125	0,749	0,19829	0,15033
w250	0,699	0,22728	0,20406
expanding	0,723	0,21568	0,18706

w250 оказался одним из худших pre-2025 калибраторов. Его известные открытые числа остаются красивыми (AUC 0,644, Brier 0,11303), но это режимный hindsight, а не устойчиво выбранное окно. Selector сохраняет T25.

w30 второй раз улучшает Brier/AUC на screen, однако ECE ухудшается на +0,01058 при разрешённых +0,005. Следующий допустимый тест - заранее заданное слабое смешивание T25 и w30, которое уменьшает calibration shock. Нельзя возвращаться к w250, ручному 2022-switch или подбирать blend по 2025-2026.

32. T28: слабый w30 не прошёл nested validation

Уровень улучшился, междневной порядок - нет

T28 зафиксировал веса 10/20/30/40/50%. Зрелая часть 2024-Q3 выбирала beta, зрелая Q4 отдельно подтверждала его; 2025-2026 не влиял на решение.

Этап	Выбранный beta	Δ AUC	Δ Brier	Δ ECE	Решение
Q3 screen	0,50	+0,04284	-0,00804	-0,03612	выбрать
Q4 validation	0,50	-0,03794	-0,00346	-0,02698	отклонить

Даже beta 0,10 на Q4 снизила AUC на 0,00772 при разрешённых 0,005. Итоговая модель поэтому побитово равна T25.

Почему так возможно при «одном intercept»: на каждом отдельном дне поправка общая и монотонная, но завтра β уже другой. Значит, порядок между двумя днями может поменяться. В Q3 эта перестановка помогала, в Q4 - вредила.

На открытом периоде beta 0,10 чуть улучшает Brier 0,11825→0,11772 и почти сохраняет AUC, но ECE delta +0,00534 едва превышает gate. Подбирать 0,09 после этого наблюдения нельзя. Следующая корректная гипотеза - вычислять level только на границе крупного периода и удерживать его неизменным внутри, сохраняя rank.

33. T29: крупный период тоже не решил drift

Месячный уровень улучшил probability, но сломал перенос rank

T29 заранее зафиксировал 10 способов менять intercept только на границе месяца или квартала. Для каждой границы разрешены лишь уникальные h20-исходы, которые успели созреть с двухдневным embargo. Внутри периода logit-поправка постоянна.

Этап	Модель	AUC T25 → candidate	Brier T25 → candidate	Решение
Q3 screen	month w30, beta 1,00	0,5777 → 0,6669	0,10820 → 0,09662	выбрать
Q4 validation	тот же frozen candidate	0,7002 → 0,6553	0,20886 → 0,20691	отклонить

На Q4 также улучшились log-loss и ECE, но AUC потерял 0,04486 при разрешённых 0,005. Причина: внутри месяца порядок действительно сохраняется, но разные месяцы получают разные константы и меняют взаимный rank. Сдвиг target rate с 11,25% в Q3 до 29,06% в Q4 сделал эту перестановку нестабильной.

На открытых 2025-2026 несколько невыбранных controls выглядят лучше отдельных метрик, но их нельзя повышать после просмотра. Итоговая модель равна T25; production/router не меняются. Следующий честный источник решения - prospective shadow, а не ещё один вес на уже открытой истории.

34. T30: режим нельзя выбирать задним числом

Pre-SVO rank и post-SVO map развернулись после screen

T30 обучил три rank-модели только до 2022, откалибровал probability на фиксированном post-SVO окне 2022, выбрал candidate на 2023 и оставил 2024 для validation. 2025-2026 ничего не выбирал.

Период	Frozen identity AUC	All-history AUC	All Platt Brier
2023 screen	0,5884	0,4904	0,20723 против 0,22651
2024 validation	0,5009	0,6245	0,15446 против 0,16496
Open 2025-2026	0,3764	0,7495	0,11827 против T25 0,12932

В 2023 all-history улучшала proper scores, но была хуже случайного порядка; recent2y давала AUC 0,6313, однако не проходила log-loss. Feasible-кандидатов не было, поэтому screen сохранил identity и validation формально не запускала замену вторым вариантом.

Поздние цифры очень сильные: половинная Platt-карта на open имеет Brier 0,11881 и ECE 0,03357, полный mapping - AUC 0,7495 и Brier 0,11827. Но выбрать их можно только после знания 2024-2026. Это frozen prospective-гипотеза, а не новая temperature. Календарный switch «после СВО» в router не добавлен.

35. T31: причинная адаптация режима без календаря

Online Hedge с только созревшим feedback

T31 проверил, можно ли заметить смену режима не правилом «после такого-то года», а только по уже известным ошибкам трёх frozen h20-экспертов. Перед каждой датой в веса попадают лишь outcomes, для которых завершились все h20 публикаций и прошёл embargo 2 дня. Прогноз текущей даты и будущие ответы не используются.

Проверено 16 заранее зарегистрированных сочетаний скорости обучения ``eta`` и возврата доли веса ``gamma``. 2023 выбирал одну строку, 2024 мог только подтвердить выбранную, 2025-2026 ничего не выбирал.

Честный итог и сильная гипотеза

Срез / модель	AUC	Brier	Log-loss	ECE
2023 identity	0,5884	0,22651	0,64313	0,18576
2023 лучший баланс, не прошёл	0,6041	0,19114	0,56730	0,03006
Open T25	0,5605	0,12932	0,43650	0,04677
Open Hedge e2/g0, не выбран	0,7495	0,11881	0,38862	0,03357

Лучший screen-баланс улучшил все proper scores, но поднял AUC лишь на 0,01571 при заранее заданном gate +0,020. Недобор 0,00429 означает ноль feasible-строк; формальный selector сохранил identity, ``passed=false``.

Невыбранный ``eta=2, gamma=0`` затем резко обогнал T25 на открытом периоде. Это показывает, что причинное перераспределение весов действительно может закрыть режимный разворот T30. Но 2025-2026 уже многократно просмотрен, поэтому модель заморожена только как prospective shadow, а runtime router не изменён.

Аудит независимо восстановил все смеси из дневных весов, проверил maturity и publication cutoffs, нормировку весов, screen/fallback и невлиание будущих targets на исторический префикс.

36. T32: OOS warm-up ухудшил перенос

Прошлый квартал закрепил уже уходящий режим

T32 проверил, не был ли провал T31 следствием старта с равными весами. Rank обучен только до 2022, probability-map - на созревшем апреле-июле 2022. После двухмесячного gap T4-compatible anchor обучен на 01.10.2022, а 325 строк октября-декабря стали отдельным OOS warm-up.

К первой screen-дате уже было доступно 42 fully mature feedback batches. Но быстрый no-share Hedge к концу 2022 отдал 99,61% веса recent2y-эксперту и перенёс это состояние в следующий год.

Срез / модель	AUC	Brier	Log-loss	ECE
2023 identity	0,5884	0,22651	0,64313	0,18576
T32 лучший AUC	0,5522	0,19461	0,57847	0,06539
T31 cold-start лучший AUC	0,6041	0,19114	0,56730	0,03006
2024 T32 e2/g0.01, не выбран	0,6316	0,15332	0,48104	0,02834

На 2023 feasible-строк нет, поэтому selector снова сохранил identity. На 2024 все 16 кандидатов диагностически проходят gates, но подмена screen-победителя запрещена. На open лучший warm control улучшает T25 до AUC 0,675 и Brier 0,12363, однако остаётся слабее T31 control около 0,750/0,1188.

Вывод: проблема не в недостатке warm-up. Недавний успешный режим может причинно, но ошибочно закрепить эксперта перед разворотом. Слепое recent-data weighting исключено; следующий адаптер должен стабилизировать междневной rank или использовать observable state. Production router не изменён.

37. T33: quarterly stacking почти прошёл

Вес фиксирован внутри квартала

T33 оценивал simplex-веса трёх frozen экспертов только на границе квартала по предыдущим полностью созревшим h20 outcomes. Затем один набор весов применялся ко всем публикациям квартала. Grid состоял из 4 окон feedback и 4 ridge к равным весам; pre-2023 warm-up не использовался.

Срез / модель	AUC	Brier	Log-loss	ECE
2023 identity	0,58840	0,22651	0,64313	0,18576
2023 w125/r1	0,60680	0,19007	0,56511	0,02435
2024 w125/r1	0,61988	0,15645	0,48795	0,01896
Open T25	0,56054	0,12932	0,43650	0,04677
Open w250/r0, не выбран	0,72503	0,11986	0,39346	0,03663

На screen лучший AUC delta равен +0,01840 при frozen gate +0,020. Не хватило 0,00160. Proper scores улучшены сильно, но near miss не является pass: менять порог или донастраивать ridge после результата запрещено. Формальный selector снова вернул identity, `passed=false`.

Тот же w125/r1 проходит все gates на 2024, а невыбранный w250/r0 выглядит сильно на validation и open. Но ни 2024, ни 2025-2026 не могут заменить screen.

Сравнение механизмов подтверждает гипотезу о rank-noise: T32 warm-up дал максимум AUC 0,5522, T31 daily Hedge - 0,6041, T33 quarterly hold - 0,6068. Квартальная стабилизация является лучшим направлением адаптации, но пока только prospective control. Runtime и push не изменены.

38. T34: safe cold start проходит протокол

Отсутствие feedback больше не считается равной смесью

T34 изменил ровно одно правило T33. Если на границе квартала доступно меньше 20 полностью созревших h20 feedback-batches, выход остаётся равным identity. После накопления данных используется прежний `qstack\_w125\_r100`; внутри квартала ничего не меняется. Порог 20 унаследован из T33, новой сетки нет.

Период / модель	AUC	Brier	Log-loss	ECE
2023 identity	0,58840	0,22651	0,64313	0,18576
2023 T34	0,68834	0,18325	0,54824	0,06210
2024 T34	0,61988	0,15645	0,48794	0,01896
Open T25	0,56054	0,12932	0,43650	0,04677
Open T34	0,63975	0,12548	0,41424	0,03766

T34 проходит frozen screen и disjoint validation. Эффект объясняется Q1-2023: без единого eligible batch равная смесь T33 дала AUC 0,4096, тогда как identity сохранил нейтральный 0,5000. Ошибка нарушала и общий межквартальный rank.

На open paired bootstrap доказывает преимущество T34 над identity: Brier CI полностью ниже нуля, AUC CI выше нуля для блоков 20 и 50 дней. Против T25 средние метрики лучше, но интервалы пересекают ноль. Идея появилась после T33, поэтому `historical\_protocol\_passed=true`, но `production\_promoted=false`. Router и push не изменены; кандидат заморожен для prospective проверки.

39. T35: часы не равны информационному состоянию

Первая попытка склеить h20 на весь день

T35 включал T34 в 00:15, 06:00, 09:15 и 10:15, сохранял T19 внутри рынка и включал T22 после calendar-assumed receipt. Это был один заранее зарегистрированный route без подбора часов по новому результату.

Сценарий	Brier: identity -> T35	AUC: identity -> T35
Calendar receipt replay	0,11903 -> 0,11562	0,5659 -> 0,6426
No same-day receipt	0,11754 -> 0,11617	0,6005 -> 0,6336

Pooled картина хорошая, 38 из 40 состояний проходят. Но 10:15 не проходит в обоих сценариях: Brier CI пересекает ноль, AUC CI пересекает ноль, ECE delta равна +0,01054. На части дат к 10:15 уже существует честный market prefix, а часовой router безусловно заменял его history-моделью.

Это важный отрицательный результат. Фаза не должна вычисляться как ``clock >= X``; она должна читаться из последнего действительно доступного источника. T35 отклонён, production не менялся.

40. T36: правильный route, слишком сильная вероятность

Источник вместо часов

T36 применяет T34 только при `snapshot\_source\_kind == cbr\_history`, T22 только на receipt-dependent replay, а market/bridge/perpetual/hold оставляет побитово равными T19. На выходных и при пропусках работает то же правило: важен source, а не календарное время.

Сценарий	Brier: identity -> T36	AUC: identity -> T36	ECE delta
Calendar receipt replay	0,11903 -> 0,11345	0,5659 -> 0,7018	+0,00448
No same-day receipt	0,11754 -> 0,11347	0,6005 -> 0,7024	+0,00947

Оба pooled Brier CI ниже нуля, оба AUC CI выше нуля. T22 after receipt имеет AUC 0,738; raw T34 history - 0,650. Значит, источник и rank работают.

Но 12 локальных дневных состояний ухудшили ECE больше допустимых +0,01, до максимума примерно +0,0177. Для виджета это принципиально: число 70 должно означать около 70%, а не только высокий rank. Gate не ослаблен, T36 отклонён.

41. T37: h20 route проходит все ретроспективные gates

Один фиксированный calibration repair

На history-строках T37 берёт среднее identity и T34 в log-odds:

``sigmoid(0.5 * logit(identity) + 0.5 * logit(T34))``.

Вес 0,5 зарегистрирован как единственный; alpha-grid не запускался. T22 после receipt и T19 на остальных источниках не меняются.

Сценарий	Brier	Log-loss	AUC	ECE
Identity, calendar	0,11903	0,39993	0,5659	0,03492
T37, calendar	0,11511	0,38586	0,6568	0,03355
Identity, no receipt	0,11754	0,39395	0,6005	0,03196
T37, no receipt	0,11525	0,38580	0,6541	0,03068

Оба pooled bootstrap gate, оба component gate и все 40/40 объединённых `scenario x clock` states проходят. History-component одновременно улучшает Brier -0,00442, log-loss -0,01577, AUC +0,13286 и ECE -0,00722.

Статус всё равно честно ограничен: `retrospective\_route\_passed=true`, `production\_promoted=false`. Ремонт придуман после T36, а 2025-2026 уже открыт. T37 нужно заморозить и проверить на следующих genuinely prospective outcomes; подбирать 0,4/0,6 задним числом нельзя.

42. T38: локальная устойчивость неполная

Frozen T37 отдельно по валютам и годам

T38 не меняет ни одной вероятности. Он группирует T37 по валюте, году и `валюта x год`, а затем повторяет парный circular moving-block bootstrap по целым датам с блоками 20 и 50 дней.

Срез	Clock pass	Pooled pass	Вывод
Валюта	169 / 200	9 / 10	no-receipt TJS превышает ECE gate
Год	80 / 80	4 / 4	результат переносится между 2025 и 2026
Валюта x год	370 / 400	12 / 20	малые группы дают широкие CI

Brier улучшается во всех 680/680 локальных point-срезах, AUC - в 674/680. Но полный frozen gate проходит только в 619/680 clock-строках и 25/34 pooled группах. Например, pooled no-receipt TJS имеет Brier delta -0,00206 и AUC delta +0,04975, оба интервала проходят, но ECE delta +0,01014 превышает лимит +0,01 на 0,00014.

Это не повод ослабить лимит или подобрать TJS-вес на 2025-2026. Корректный статус: T37 силен pooled и по годам, но локальная валютная калибровка ещё не production-proven. T39 ниже проверяет disjoint pre-2025 repair без выбора на открытом периоде.

43. T39: currency alpha не перенеслась

Aggregate стал лучше, локальная устойчивость хуже

T39 выбрал alpha из `0/0,25/0,5/0,75/1` отдельно для каждой валюты на mature OOS 2023 и проверил его на disjoint mature OOS 2024. Только AMD и UZS сохранили alpha=1; KGS/KZT/TJS вернулись к T37 alpha=0,5.

Проверка	T37	T39
Clock-local pass	619 / 680	594 / 680
Pooled local pass	25 / 34	22 / 34
Pooled year pass	4 / 4	3 / 4

При этом T39 прошёл 40/40 общих clock-gates против T37. Pooled Brier улучшился ещё на -0,00072/-0,00078, AUC - на +0,020/+0,022. Средняя метрика скрыла 25 новых failures: 17 для AMD-2026, 7 для UZS и одну объединённую строку 2026.

Например, calendar AMD-2026 имеет Brier delta -0,00798 и AUC delta +0,14270, но ECE ухудшается на +0,02115. Эксперт лучше ранжирует, однако число 0-100 становится локально переуверенным. `retrospective\_repair\_passed=false`: currency-map отклонена, T37 остаётся неизменным. Следующий шаг требует новых prospective outcomes или независимого source-state replay.

44. T40: длинная история не подтверждает единый эксперт

2019-2024 открыты только по заранее заданному протоколу

T40 ежегодно обучал одну `StandardScaler + L2 LogisticRegression` на данных до предыдущего года, калибровал frozen score на предыдущем году и смешивал его 50/50 в log-odds с причинной базовой частотой. Использованы те же 41 history-only CBR-признак без market/receipt-информации. Никакого выбора весов, валют или годов после результата не было.

Стадия	Brier delta	Log-loss delta	ECE delta	AUC delta	Local pass
2019-2022 screen	+0,00654	+0,02260	+0,02503	+0,00439	0 / 9
2023-2024 validation	-0,00239	-0,00927	-0,01865	+0,09832	5 / 7

Screen провален во всех локальных группах. Самый сильный regime failure - 2022: Brier delta +0,02122, ECE +0,08080 и AUC delta -0,10322. Но это не только СВО: каждый год 2019-2022 нарушает хотя бы один допуск. Validation лучше за счёт 2023, однако 2024 теряет AUC, KZT слегка нарушает proper-score допуски, а оба bootstrap-интервала пересекают ноль.

По preregistration open 2025-2026 не был оценён: `historical\_gate\_passed=false`, `open\_evaluated=false`. Аудит пересобрал все annual fits, prior, bootstrap и gates; future-prefix corruption прошла. T37 остаётся без изменения. Результат отвергает идею одного стационарного history-only эксперта и усиливает требование state-aware prospective shadow.

45. T41: mature feedback не успевает за сменой режима

Причинная адаптация есть, устойчивого улучшения нет

T41 проверил простой автоматический предохранитель для T40. В начале каждого квартала он брал последние 125 публикационных дат, у которых h20-исход уже полностью известен с двухдневным embargo, и одной закрытой формулой вычислял вес между causal prior и T40. Вес замораживался на квартал и был общим для всех валют. Никакой сетки, знания текущего квартала или выбора по 2025-2026 не было.

Стадия	Brier delta	Log-loss delta	ECE delta	AUC delta	Local pass
2019-2022 screen	+0,00425	+0,01279	+0,01671	+0,01264	2 / 9
2023-2024 validation	-0,00113	-0,00425	-0,01166	+0,07815	6 / 7

Поздняя validation стала лучше prior в точке, но Brier и AUC paired CI всё ещё пересекают ноль. На screen Brier CI целиком выше нуля: механизм доказанно ухудшает proper score. Особенно показательно, что `alpha=1` включался на 2020-Q1 и 2022-Q2, а вскоре снова падал к нулю. Запаздывающая квартальная ошибка не распознаёт новый экономический режим заранее.

Frozen gate остановил эксперимент до оценки model metrics 2025-2026. Реконструкционный аудит и порча будущего пройдены. T41 не меняет T37 и production: следующий challenger должен использовать наблюдаемое source/regime state, а не ещё один календарный вес на уже открытой ретроспективе.

46. T42: OOD-state распознал шок, но не спас модель

Необычность данных снижает вред, но не создаёт правильный прогноз

T42 вычислял без target удалённость текущих 41 CBR-признака от training distribution T40. Один заранее заданный вес $\alpha = \min(1, 1/\text{mean}(z^2))$ плавно возвращал вероятность к causal prior, когда состояние становилось незнакомым. Ни сетки, ни CBO-флага, ни выбора на 2025-2026 не было.

Стадия	Brier delta	Log-loss delta	ECE delta	AUC delta	Local pass
2019-2022 screen	+0,00262	+0,01205	+0,01514	+0,00337	0 / 9
2023-2024 validation	-0,00218	-0,00852	-0,02105	+0,10370	5 / 7

Механизм заметил 2022: средняя OOD-energy выросла до 3,219, средний вес T40 упал до 0,619, тогда как в 2019/2021 полный вес сохранялся почти в 98% строк. Screen-вред T40 по Brier уменьшился с +0,00654 до +0,00262, но 95%-интервал T42 всё ещё целиком выше нуля. То есть novelty правильно предупреждает «этому эксперту меньше доверия», но не говорит, какой прогноз будет верным после смены связи feature→target.

Frozen gate остановил эксперимент до target/model metrics 2025-2026. Аудит воспроизвёл scaler states, predictions, bootstrap и future-prefix corruption. T37 не изменён; следующий challenger должен различать наблюдаемый механизм режима, а не только расстояние от прошлого.

47. Строгая сверка с ТЗ

Что закрыто и что остаётся открытым

Требование	Статус	Комментарий
5 валют и 5+ лет ЦБ	PASS	нормализация номинала, публикационный индекс
Momentum/level/reversal/seasonality	PASS	единая матрица с выводом об исключении
Классический ML	PASS	модели объяснимы, GenAI не входит в сигнал
Две цели, h1/3/5/10/20	PASS	AP37 проходит point threshold
Lift $\geq 1,3$ по коридорам	PASS point-wise	минимум window-close h20 = 1,308
Частота и кучность	PASS point-wise	около 1/неделю, cap 2
Walk-forward, as-of	PASS	mature labels, embargo, corruption tests
Произвольная дата/время	PASS	runtime API и T19 grid
Fast vs slow	PASS proxy	цена ожидания посчитана на ЦБ
Тексты и конфликты	PASS	past/present-only, AP37 router
Реальный receipt ЦБ	PARTIAL	production gate готов, история timestamp неполна
h20 any-time	PARTIAL, сильный pooled/year shadow	T37 40/40 pooled state; T38 619/680 local; T39/T41/T42 repair отклонены; T40 long-history gate провален до открытия 2025-2026
Fresh independent holdout	GAP	нужен prospective shadow
Реальная банковская экономика	GAP за рамками хакатона	нужен пилот с quote и клиентским holdout

Итог: численная сигнальная часть соответствует основным point-условиям ТЗ. Самые важные оговорки не меняют scorecard, но запрещают завышать вывод: ретроспектива открыта, официальный курс не равен исполнению, Т37 ещё не видел нового независимого периода, а Т38 обнаружил валютно-локальные calibration gaps. Т39 подтвердил, что улучшение aggregate Brier/AUC само по себе их не закрывает. Т40 дополнительно показал, что хороший 2023-2024 режим не переносится на 2019-2022: длинная OOS-история важнее красивого позднего среднего. Т41 показал, что причинная квартальная усадка по mature feedback смягчает, но не устраняет этот regime failure. Т42 показал то же для label-free OOD-усадки: 2022 распознаётся как необычный, но screen остаётся хуже causal prior.

48. Итоговая схема решения

Что делает система в production

1. Ingestion сохраняет каждый курс и свечу с фактическим временем получения.
2. Feature layer строит только признаки из завершённого прошлого.
3. Router выбирает expert по валюте, горизонту и информационной фазе.
4. Probability calibrator выдаёт температуры, magnitude model ожидаемые б.п.
5. Freshness layer добавляет возраст, уверенность и ограничения текста.
6. Sparse policy отдельно решает `push\_now` с cooldown и cap.
7. Интерфейс при каждом открытии повторно запрашивает актуальное состояние.
8. Decision log хранит входы, версии, причины и фактический исход.

Самый сильный открытый ретроспективный point-result основной задачи: AP37 h5 lift 2,509 при частоте 1,038 сигнала на валюту в неделю и future-only benefit +133,73 б.п. Самый полезный результат any-time контура: h5 становится устойчиво сильнее прошлого baseline примерно с 11:45, достигает AUC около 0,70 до receipt и около 0,72 после receipt.

Главный следующий модельный шаг: T37 заморозить как единый h20 prospective shadow. До рынка он осторожно использует T34 history, внутри рынка оставляет T19, после реального receipt подключает T22. T35 доказал, почему часы плохи, T36 - почему raw rank нельзя без усадки называть вероятностью, T37 прошёл 40/40 объединённых scenario-clock gates. T38 подтвердил перенос по годам, но обнаружил currency-local ECE и маломощные currency-year срезы. T39 уже проверил disjoint pre-2025 currency-map: aggregate стал лучше, local stability хуже. T40 затем провёл annual replay 2019-2024 и остановился до открытия 2025-2026: screen 2019-2022 провален, хотя 2023-2024 выглядел лучше. T41 причинно адаптировал вес T40 по mature квартальной ошибке, но также не прошёл screen и не открыл поздние model metrics. T42 распознал covariate shift без target и сократил вред, но screen всё равно проиграл prior. Следующий доказательный шаг - новые prospective outcomes и observable state-aware challenger, различающий механизм режима, а не настройка ещё одного веса на открытом интервале. Главный следующий бизнес-шаг: заморозить систему, подключить реальные bank quotes и запустить user-level prospective pilot.